UNIVERSIDAD DE INGENIERÍA Y TECNOLOGÍA

CARRERA DE CIENCIA DE LA COMPUTACIÓN



SENSE: Resource-Aware Multimodal Small Language Model Agents for Context Understanding on Edge IoT Devices

TRABAJO DE INVESTIGACIÓN

Para optar el grado de Licenciado en Ciencia de la Computación

AUTOR(ES)

Fabrizzio Nicolay Vilchez Espinoza

Adrian Antonio Auqui Perez

ASESOR(ES)

Prof. Dra. Aurea Soriano Vargas

Prof. Dr. Victor Martinez Abaunza

Lima - Perú

2026

Dedicatoria:

xxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxx
xxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxx
xxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxx
xxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxx
xxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxx
XXxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxx

Agradecimientos:

xxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxx
xxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxx
xxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxx
xxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxx
xxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxx
xxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxx

TABLA DE CONTENIDO

Pág.

INTRODUCCIÓN 1
Presentación del tema de investigación 1
Descripción de la situación problemática 2
Formulación del problema 3
Objetivos de investigación 4
Justificación 5
Alcance y limitaciones / restricciones 6

CAPÍTULO I REVISIÓN CRÍTICA DE LA LITERATURA 8
1.1 Introducción 8
1.2 Integración multimodal y comprensión del entorno 9
1.3 Antecedentes complementarios sobre ocupación y fusión sensorial 10
1.4 Coordinación de agentes y razonamiento multimodal 12
1.5 Eficiencia de SLM en dispositivos Edge 14
1.6 Síntesis crítica y brecha de investigación 17
1.7 Aporte propuesto de SENSE 18

CAPÍTULO II MARCO TEÓRICO 20
2.1 Computación consciente del contexto 20
2.2 Fusión de información multimodal y temporalidad 22
2.3 Incertidumbre y adquisición adaptativa de información 23

2.4 Agentes, orquestación y máquinas de estados 25
2.5 SLM local e integración de información visual 26
2.6 Eficiencia computacional y energética en el borde 28

CAPÍTULO III MARCO METODOLÓGICO **31**

3.1 Diseño del estudio 31
3.2 Arquitectura de SENSE 32
3.3 Máquina de estados y política del orquestador 34
3.4 Montaje y preparación del piloto 35
3.5 Escenarios, referencia humana y comparadores 36
3.6 Procedimiento y métricas 38
3.7 Análisis y reproducibilidad 41

ÍNDICE DE TABLAS

Tabla 3.1 Contrato mínimo de los agentes de percepción propuestos. . . . 33
Tabla 3.2 Transiciones principales de la máquina de estados del orquestador. 35
Tabla 3.3 Comparaciones previstas y factor que se modifica. 38

ÍNDICE DE FIGURAS

Figura 3.1 Arquitectura funcional propuesta de SENSE. Esquema pendiente de elaboración. 33
Figura 3.2 Máquina de estados de ejecución propuesta para el orquestador. Esquema pendiente de elaboración. 35
Figura 3.3 Regiones de observación del montaje experimental. Plano pendiente del piloto. 36
Figura 3.4 Cronología de un escenario con cambio de presencia y evidencia incompleta. Esquema ilustrativo pendiente. 37
Figura 3.5 Protocolo de evaluación y frontera de medición eléctrica. Esquema pendiente de elaboración. 39

INTRODUCCIÓN

Presentación del tema de investigación

La integración de inteligencia artificial en el Internet de las Cosas (IoT) permite desarrollar sistemas capaces de interpretar información del entorno mediante sensores y dispositivos heterogéneos. En aplicaciones como los campus inteligentes, estas tecnologías facilitan el monitoreo de condiciones ambientales, ocupación y consumo energético. Sin embargo, la diversidad de fuentes de información introduce desafíos de integración y procesamiento, especialmente cuando el sistema debe operar con recursos computacionales limitados [1].

Los avances en modelos de lenguaje pequeños (*Small Language Models*, SLM) han ampliado las posibilidades de incorporar capacidades de interpretación y razonamiento en dispositivos de borde. Investigaciones recientes estudian su despliegue mediante técnicas de optimización, así como mediante arquitecturas multiagente que combinan modelos especializados con mecanismos de coordinación. No obstante, su ejecución continúa condicionada por la memoria disponible, la capacidad de procesamiento y el consumo energético [2–4].

En este contexto, la presente investigación propone **SENSE (Resource-Aware Multimodal Small Language Model Agents for Context Understanding on Edge IoT Devices)**, una arquitectura multiagente multimodal adaptativa para la comprensión contextual de entornos interiores. La propuesta integra sensores ambientales, detección de presencia y percepción visual mediante una representación del estado del entorno, a partir de la cual un orquestador determina cuándo adquirir información adicional o recurrir al razonamiento mediante un SLM. El sistema será implementado sobre una Raspberry Pi 5 de 8 GB y evaluado en aulas y laboratorios universitarios, considerando tanto la calidad de comprensión contextual como la eficiencia computacional y energética.

Descripción de la situación problemática

El monitoreo inteligente de aulas y laboratorios requiere interpretar condiciones cambiantes a partir de información ambiental, presencia humana y observaciones visuales. Sin embargo, cada modalidad proporciona información parcial: un radar puede detectar presencia sin determinar de manera confiable la cantidad de ocupantes, mientras que las mediciones ambientales no permiten identificar por sí solas las causas de una variación. La combinación de estas fuentes puede proporcionar información complementaria, aunque también introduce nuevos requerimientos de adquisición y procesamiento.

Una estrategia que ejecuta visión o inferencia de lenguaje de forma continua o periódica, sin relacionar esas activaciones con una necesidad de información, puede realizar un procesamiento que no modifica la interpretación requerida. Este problema cobra relevancia en dispositivos Edge, donde la ejecución de modelos de inteligencia artificial está condicionada por restricciones de memoria, de procesamiento y de energía [4, 5]. Los sensores de bajo costo pueden mantenerse en muestreo periódico; la adaptación propuesta se centra inicialmente en decidir cuándo procesar la visión, renovar observaciones vencidas o invocar el SLM.

Aunque existen investigaciones que integran SLM con información sensorial y arquitecturas multiagente coordinadas mediante máquinas de estados [3, 6], resulta necesario determinar cómo utilizar una representación contextual para decidir qué información adquirir y qué componentes ejecutar. En particular, se requiere evaluar si una estrategia adaptativa puede mantener una identificación adecuada de los estados del entorno, reduciendo el procesamiento innecesario, y establecer cuándo el razonamiento mediante un SLM aporta beneficios frente a alternativas deterministas.

Para esta investigación, la comprensión contextual se evaluará mediante dimensiones separadas: presencia en la región cubierta, conteo visual cuando sea necesario, cambios ambientales observados y disponibilidad o calidad de la información, incluyendo estados desconocidos, antiguos o contradictorios. Un evento relevante será una transición o condición previamente definida que exija registro o adquisición adicional, como un cambio de presencia, una observación vencida, un sensor sin datos o una discrepancia entre modalidades; el término no implica por sí mismo una condición peligrosa. Se considerará procesamiento innecesario la activación de visión o SLM que no responda a una necesidad de información predefinida ni modifique una decisión contextual requerida. Estas definiciones se concretarán mediante etiquetas, ventanas temporales y criterios de referencia en la metodología.

Formulación del problema

La investigación busca determinar el efecto de integrar información multimodal y gestionar adaptativamente su adquisición y procesamiento en un dispositivo Edge con recursos limitados.

Pregunta general

¿En qué medida una arquitectura multiagente multimodal adaptativa, basada en una representación de estados contextuales y consciente de recursos, influye en la calidad de identificación de dimensiones contextuales y en los costos computacionales y energéticos del monitoreo inteligente de aulas y laboratorios universitarios mediante dispositivos Edge IoT?

Preguntas específicas

1. ¿Qué efecto tiene la integración de información ambiental, presencia humana y percepción visual sobre la identificación de las dimensiones contextuales definidas, frente al uso de modalidades individuales?

2. ¿En qué medida una estrategia de adquisición adaptativa reduce las activaciones de visión y de SLM, el tiempo de procesamiento y la latencia, y qué efecto produce en los eventos omitidos y las falsas alarmas?

3. ¿Cuál es el efecto de incorporar razonamiento mediante un SLM sobre la interpretación del contexto, las afirmaciones no sustentadas, las solicitudes innecesarias de información, la latencia y el consumo de recursos, en comparación con estrategias deterministas que reciben la misma evidencia?

Objetivos de investigación

Objetivo general

Diseñar, implementar y evaluar **SENSE**, una arquitectura multiagente multimodal adaptativa y consciente de recursos para la comprensión contextual de aulas y laboratorios universitarios mediante dispositivos Edge IoT.

Objetivos específicos

1. Diseñar una representación de estados contextuales que integre información ambiental, presencia humana y percepción visual, diferenciando las observaciones disponibles, desconocidas, antiguas o contradictorias, y las necesidades de adquisición adicional.

2. Implementar una arquitectura multiagente sobre una Raspberry Pi 5, mediante un orquestador desarrollado en Rust que coordine sensores, percepción visual y un SLM local.

3. Desarrollar un mecanismo de adquisición adaptativa que determine la activación de visión y SLM según las necesidades de información del estado contextual y los recursos disponibles.

4. Integrar un SLM para interpretar información contextual estructurada y generar salidas que distingan hechos observados, inferencias, información desconocida, explicaciones y recomendaciones no críticas.

5. Evaluar la identificación de dimensiones contextuales mediante matrices de confusión, macro-F1, eventos omitidos, falsas alarmas y error de conteo cuando corresponda, junto con latencia, activaciones de componentes, utilización de CPU y memoria, potencia y energía, mediante comparadores y pruebas de ablación.

Justificación

Desde el punto de vista científico, la investigación busca aportar evidencia experimental sobre la relación entre integración multimodal, comprensión contextual y adquisición adaptativa de información. Aunque existen antecedentes de sistemas IoT con SLM y arquitecturas multiagente especializadas, resulta pertinente estudiar cuándo la información de una modalidad adicional o el razonamiento mediante un modelo de lenguaje producen beneficios que justifican su costo computacional [3, 6].

Desde el punto de vista tecnológico, SENSE propone coordinar diferentes mecanismos de percepción y razonamiento mediante un orquestador implementado en Rust. La evaluación conjunta de calidad contextual, latencia, memoria, potencia y energía permitirá analizar los compromisos entre capacidad de comprensión y utilización de recursos, sin asumir que la incorporación de más modelos o agentes garantiza un mejor desempeño.

Desde el punto de vista práctico, las aulas y laboratorios universitarios proporcionan escenarios donde pueden observarse variaciones de ocupación y condiciones ambientales. Estos espacios permitirán desarrollar experimentos controlados y

evaluar la capacidad del sistema para interpretar situaciones reales, con posibilidades de adaptar posteriormente la arquitectura a otros entornos interiores.

Alcance y limitaciones / restricciones

La investigación comprende el diseño, implementación y evaluación experimental de un prototipo de SENSE sobre una Raspberry Pi 5 de 8 GB. Se integrarán cuatro dispositivos: SHT40 para temperatura y humedad, ENS160 para indicadores ambientales, HLK-LD2410C para presencia y movimiento, y una cámara Sony IMX219 para percepción visual. El procesamiento y la inferencia del SLM se realizarán localmente.

El prototipo será evaluado en aulas y laboratorios universitarios mediante escenarios con diferentes condiciones de ocupación, ambiente y disponibilidad de información. Se compararán estrategias de procesamiento continuo, mecanismos deterministas y la arquitectura adaptativa propuesta, utilizando métricas de calidad contextual, latencia, activaciones de componentes, utilización de recursos, potencia y energía. La medición eléctrica se plantea por ejecuciones completas mediante un medidor de enchufe con pantalla, situado entre la toma y la fuente de alimentación; el modelo, sus funciones, exactitud y resolución se comprobarán antes de fijar el protocolo y reportar resultados de energía.

Entre las limitaciones se encuentran la capacidad computacional de la Raspberry Pi, la cobertura del radar y las condiciones de captura de la cámara. El ENS160 proporciona indicadores de gases y dióxido de carbono equivalente estimado, pero no mide directamente la concentración de CO_2 ni constituye un detector certificado de humo o contaminantes peligrosos. Por tanto, el sistema no se utilizará para emitir diagnósticos de seguridad ambiental.

La investigación no contempla entrenar un modelo de lenguaje desde cero, realizar reconocimiento facial ni automatizar decisiones críticas. La captura de

imágenes se realizará únicamente con autorización institucional y consentimiento aplicable, minimizando almacenamiento, retención e identificación de personas. Los resultados estarán limitados al hardware y los escenarios experimentales seleccionados, por lo que su generalización a otras plataformas y entornos requerirá evaluaciones adicionales.

CAPÍTULO I

REVISIÓN CRÍTICA DE LA LITERATURA

1.1 Introducción

La incorporación de inteligencia artificial en dispositivos IoT ha impulsado el desarrollo de sistemas capaces de interpretar información del entorno y ejecutar tareas localmente. Sin embargo, integrar múltiples fuentes de información y modelos de inteligencia artificial introduce desafíos relacionados con la comprensión contextual, la coordinación de componentes y el uso eficiente de recursos computacionales. La presente revisión crítica parte de siete trabajos sobre integración IoT, agentes y SLM, y los contrasta con estudios sobre ocupación, fusión sensorial y activación selectiva de procesamiento en edificios. Su propósito es establecer los fundamentos y delimitar la brecha de investigación de SENSE sin confundir la ausencia de un enfoque en este corpus con una afirmación de novedad universal.

El núcleo inicial se escogió mediante un criterio intencional de pertinencia: debía aportar evidencia sobre integración IoT en entornos reales, coordinación de agentes o despliegue y eficiencia de SLM en dispositivos restringidos. Los estudios de ocupación se incorporan para confrontar esa perspectiva con soluciones más próximas a la aplicación prevista. El análisis considera contribuciones, métodos, resultados y límites, prestando especial atención a las capacidades demostradas y a su relación con la arquitectura propuesta. Las conclusiones se restringen al corpus revisado y la brecha se formula en relación con esos trabajos, sin atribuir a esta revisión un carácter exhaustivo o sistemático.

1.2 Integración multimodal y comprensión del entorno

Domínguez-Bolaño et al. [1] desarrollan un sistema IoT para un campus universitario que integra dispositivos y servicios de diferentes fabricantes. Mediante cinco casos de uso reales, los autores analizan desafíos de interoperabilidad, escalabilidad, almacenamiento, procesamiento y visualización de datos. La implementación utiliza tecnologías de código abierto, como Home Assistant, InfluxDB, Grafana y Node-RED, para integrar información relacionada con calidad del aire, variables ambientales y consumo energético. Asimismo, los autores examinan el procesamiento de datos y la utilización de CPU para evaluar el funcionamiento de la infraestructura.

Este trabajo constituye un antecedente relevante para SENSE porque demuestra que los entornos universitarios permiten desarrollar aplicaciones IoT con dispositivos heterogéneos y condiciones reales de operación. No obstante, su contribución se concentra en la integración de infraestructura y servicios, sin evaluar específicamente mecanismos de comprensión contextual basados en SLM ni políticas que seleccionen dinámicamente modalidades de percepción. La diferencia es importante: integrar correctamente varios sensores permite disponer de sus observaciones, pero no determina qué información necesita el sistema para interpretar una situación ni cuándo resulta conveniente adquirirla.

Por su parte, Núñez et al. [6] proponen una arquitectura híbrida Edge–Cloud para el monitoreo y control de colonias de abejas mediante sensores IoT, modelos de lenguaje pequeños y algoritmos bioinspirados. La arquitectura utiliza información ambiental y variables relacionadas con las colmenas para generar alertas y recomendaciones mediante Phi-3.5 y TinyLlama. Además, incorpora algoritmos bioinspirados para determinar parámetros de operación y redes LSTM para realizar predicciones. Los autores reportan una reducción del 80 % en el tiempo de inspección dentro de la

aplicación estudiada, aunque este resultado corresponde al sistema integrado y no demuestra una mejora atribuible exclusivamente a los SLM.

El estudio sobre colmenas es especialmente pertinente porque demuestra que la combinación de sensores y modelos generativos en aplicaciones IoT ya cuenta con implementaciones experimentales. Sin embargo, su arquitectura no presenta como objeto central de evaluación una política que determine cuándo una modalidad adicional resulta necesaria para resolver incertidumbre contextual. En contraste, SENSE propone estudiar si una representación del estado del entorno permite decidir cuándo la información disponible es suficiente y cuándo conviene activar componentes adicionales. Esta distinción orienta la investigación desde la integración de datos hacia la selección adaptativa de información, cuyo beneficio deberá establecerse experimentalmente.

1.3 Antecedentes complementarios sobre ocupación y fusión sensorial

La detección y estimación de ocupación en edificios constituye un campo previo y directamente relacionado con SENSE. Chen et al. [7] revisan soluciones basadas en cámaras, sensores ambientales, medidores, tecnologías inalámbricas y combinaciones de múltiples fuentes. Su análisis distingue la detección de presencia de la estimación del número de ocupantes y muestra que cada modalidad presenta compromisos de precisión, costo, infraestructura y privacidad. Sun et al. [8] amplían este panorama al examinar distintos niveles de información de ocupación y prestar especial atención a métodos basados en imágenes y video. Ambos trabajos respaldan el uso de modalidades complementarias, pero también muestran que integrar más sensores no resuelve automáticamente las limitaciones de cobertura, sincronización o interpretación.

En un contexto específicamente educativo, Challa et al. [9] describen un sistema que combina video continuo y mediciones de gases para estimar ocupación en un aula y apoyar el control de climatización. El trabajo demuestra que la combinación de información visual y ambiental en aulas no es, por sí sola, una contribución nueva. Sin embargo, su procesamiento visual se ejecuta continuamente y la implementación utiliza una GPU discreta; además, su objetivo principal es estimar ocupación para HVAC, no evaluar una política que active selectivamente percepción y razonamiento sobre una Raspberry Pi. La comparación delimita mejor a SENSE: el aporte propuesto no reside en reunir cámara y sensores, sino en estudiar si el estado de conocimiento, las necesidades de información y el costo medido pueden gobernar cuándo procesar cada modalidad y cuándo invocar un SLM.

La adquisición adaptable tampoco parte de cero. Wiese et al. [10] implementan en un nodo IoT con procesador GAP9 detección visual de ocupación y muestreo ambiental con frecuencias adaptables. Su evaluación caracteriza consumo y precisión de la inferencia visual, y compara procesamiento local con transmisión de imágenes sin procesar. Se trata de un antecedente directo para el compromiso entre observación y energía, aunque su plataforma y su objetivo difieren de una Raspberry Pi que ejecuta también un SLM. Por su parte, Farrukh y Amayri [11] proponen consultas selectivas desde un modelo ligero hacia otro más potente, usando confianza y acuerdo para espaciar las consultas en tareas de ocupación y actividad. Esto muestra que la decisión de invocar procesamiento adicional según la información disponible ya se investiga; su colaboración nube–fog y destilación de conocimiento plantean un problema distinto al de seleccionar entre radar, cámara y SLM locales. Ninguno de estos contrastes autoriza a atribuir a SENSE la invención del muestreo o la inferencia selectivos.

Más próximo aún al componente visual, Qaisar et al. [12] comparan detección, seguimiento y refinamiento selectivo con modelos de razonamiento sobre video

de un laboratorio, usando anotaciones humanas por fotograma. Su intervención se concentra en resultados visuales ambiguos y evalúa después su efecto sobre entradas para control HVAC mediante simulación. El trabajo impide presentar como nuevo el uso selectivo de un modelo visión-lenguaje para corregir ocupación. Su evaluación se basa en video ya adquirido y no estudia una política que decida cuándo adquirir la imagen a partir de radar y señales ambientales, ni mide el consumo eléctrico de un sistema local completo en Raspberry Pi. Además, la energía de HVAC en la simulación corresponde al edificio modelado, no a la energía consumida por la cadena de inferencia. Así, SENSE deberá demostrar un aporte incremental distinto: selección de modalidades antes de procesar y comparación del SLM local con reglas bajo la misma evidencia.

1.4 Coordinación de agentes y razonamiento multimodal

Yang et al. [3] presentan LEAF, una arquitectura para el Internet Industrial de las Cosas basada en tres SLM especializados en planificación, ejecución e interacción. Los expertos comparten los parámetros del modelo base mediante S-LoRA y son coordinados por un motor de decisión basado en una máquina de estados finitos (*Finite State Machine*, FSM). Esta organización permite mantener un flujo de ejecución determinista y delegar decisiones específicas a los modelos. Cuando falta información necesaria para ejecutar una herramienta, el motor puede dirigir el proceso hacia una interacción adicional en lugar de continuar con parámetros incompletos.

LEAF utiliza Qwen3-4B como modelo base y combina ajuste fino supervisado con optimización mediante GRPO. Su evaluación comprende tres escenarios industriales: líneas de producción, mantenimiento de equipos y gestión energética, con cien tareas y veinte herramientas por escenario. Los autores reportan tasas de éxito de 90.53 %, 88.81 % y 89.06 %, respectivamente. Asimismo, realizan estudios

de ablación que examinan el efecto del entrenamiento especializado y del motor de decisión sobre el desempeño del sistema.

No obstante, estos resultados deben interpretarse considerando su metodología. Los conjuntos experimentales se construyen principalmente mediante generación sintética con apoyo de modelos de mayor capacidad, y parte de la evaluación automática utiliza GPT-4.1 como evaluador. Además, el análisis de eficiencia se realiza sobre una NVIDIA Jetson AGX Orin de 32 GB, mientras que otros experimentos utilizan una RTX 3090. Por tanto, los resultados no permiten establecer directamente el comportamiento de una arquitectura equivalente sobre una Raspberry Pi 5 de 8 GB ni su desempeño en la interpretación continua de observaciones físicas reales.

LEAF representa un antecedente fundamental para SENSE porque demuestra que la especialización de agentes y las máquinas de estados ya han sido investigadas. Sin embargo, su FSM organiza principalmente la ejecución de tareas y la interacción con herramientas. SENSE propone estudiar una representación diferente: el estado contextual del entorno físico, incluyendo observaciones disponibles, información faltante y necesidades de percepción. Así, mientras LEAF utiliza el contexto para completar una tarea, SENSE pretende evaluar si puede utilizarse también para determinar qué información adquirir y qué nivel de procesamiento ejecutar. Esta diferencia no implica que LEAF carezca de mecanismos contextuales, sino que ambos trabajos plantean problemas y objetivos experimentales distintos.

Yao et al. [13] presentan MiniCPM-V, una familia de modelos que integra información visual y textual mediante optimizaciones arquitectónicas y de entrenamiento. El trabajo incorpora mecanismos para procesar imágenes de alta resolución reduciendo el costo asociado a sus representaciones visuales. Los autores reportan resultados competitivos frente a modelos multimodales de mayor tamaño y presentan evaluaciones sobre dispositivos móviles, demostrando avances en el despliegue de capacidades multimodales fuera de infraestructura convencional de servidores.

Sin embargo, la ejecución de un modelo multimodal de ocho mil millones de parámetros en determinados dispositivos móviles no garantiza su viabilidad sobre una Raspberry Pi 5 que deba compartir recursos con sensores y otros procesos. Además, el enfoque de MiniCPM-V se concentra en optimizar un modelo que integra directamente visión y lenguaje, mientras que SENSE propone coordinar agentes especializados que transformen sus observaciones en una representación contextual común. Esta separación permitiría evaluar individualmente la contribución de cada modalidad y controlar cuándo se ejecuta cada componente, aunque también introduce costos de coordinación y posibles pérdidas de información durante la transformación de datos. Por ello, la conveniencia de esta estrategia deberá comprobarse experimentalmente y no asumirse como una ventaja inherente.

1.5 Eficiencia de SLM en dispositivos Edge

Driss et al. [2] presentan una revisión de más de 160 investigaciones sobre arquitecturas, optimización y despliegue de modelos de lenguaje pequeños en dispositivos IoT. Los autores analizan técnicas como cuantización, compresión y adaptación eficiente, además de restricciones de memoria, latencia y consumo energético. La revisión también examina posibilidades de razonamiento agentivo y procesamiento local, identificando desafíos relacionados con confiabilidad, evaluación y compatibilidad entre modelos y hardware.

Esta revisión proporciona un fundamento general para SENSE al establecer que la ejecución local de SLM depende de múltiples factores y no únicamente del número de parámetros. Sin embargo, sus conclusiones sintetizan resultados obtenidos mediante diferentes modelos, plataformas y tareas, por lo que no constituyen una validación experimental de una arquitectura específica. En consecuencia, demostrar nuevamente que un SLM puede ejecutarse en una Raspberry Pi no representa por sí mismo una contribución suficiente. La investigación debe determinar qué función

cumple el modelo dentro del sistema, cuándo resulta necesario utilizarlo y qué costo introduce respecto a alternativas de menor complejidad.

El aporte de modelos de lenguaje a la medición de ocupación también ha sido evaluado directamente. Qaisar et al. [14] comparan modelos de lenguaje con métodos clásicos de aprendizaje automático para detección y estimación de ocupantes a partir de datos de edificios de oficinas. Sus experimentos con dos conjuntos reales y distintos intervalos temporales aportan evidencia sobre el posible valor predictivo de modelos generativos en esta tarea. Sin embargo, el estudio examina la predicción desde datos disponibles, mientras que SENSE debe decidir qué observación adicional adquirir y contrastar el SLM con reglas que reciban exactamente el mismo contexto. Los modelos y servicios evaluados allí tampoco establecen el costo de ejecutar simultáneamente sensores, visión y un SLM local en la plataforma de esta tesis.

Qin et al. [5] investigan experimentalmente la personalización y el despliegue de modelos de lenguaje bajo restricciones de recursos. Su estudio examina la influencia del tamaño del modelo, la dificultad de la tarea, la cantidad de datos y diferentes métodos de adaptación, incluyendo ajuste eficiente de parámetros y recuperación aumentada mediante generación (*Retrieval-Augmented Generation*, RAG). Los autores encuentran que la selección de un método de personalización depende de las características de la tarea y que incrementar los parámetros entrenables o prolongar el entrenamiento no garantiza mejores resultados.

Este hallazgo resulta relevante porque cuestiona la conveniencia de incorporar técnicas como LoRA sin identificar previamente una necesidad concreta de especialización. Para SENSE, la selección del SLM deberá considerar las tareas de interpretación contextual que realmente necesite resolver, comparando su desempeño con mecanismos deterministas. No obstante, el estudio de Qin et al. se concentra principalmente en la personalización y eficiencia de modelos individuales, y no evalúa

una política de adquisición sensorial que determine dinámicamente cuándo ejecutar percepción visual o razonamiento generativo.

De manera complementaria, Nguyen y Nguyen [4] evalúan modelos de lenguaje cuantizados sobre Raspberry Pi 4, Raspberry Pi 5 y Orange Pi 5 Pro. Ollama constituye el motor común para comparar las tres placas; la comparación entre Ollama y Llamafile se realiza únicamente en Orange Pi 5 Pro debido a limitaciones de compatibilidad declaradas por los autores. El estudio analiza velocidad de generación, memoria y potencia bajo diferentes configuraciones. En sus pruebas con Ollama, la Raspberry Pi 5 mantiene tasas de generación mayores que la Raspberry Pi 4 y ejecuta modelos de hasta aproximadamente 1.5 mil millones de parámetros dentro del intervalo que los autores consideran práctico, mientras que en la Raspberry Pi 4 los modelos de mil millones de parámetros o más presentan un rendimiento considerablemente menor.

Este antecedente resulta especialmente pertinente porque incluye una Raspberry Pi 5 de 8 GB, plataforma utilizada por SENSE. Sin embargo, se trata de un preprint y sus experimentos evalúan principalmente cargas de inferencia, no el funcionamiento conjunto de sensores, visión artificial, representación contextual y coordinación de agentes. Por tanto, el rendimiento de un SLM ejecutado aisladamente no debe extrapolarse directamente al sistema completo. Asimismo, reducir el número de inferencias no garantiza necesariamente disminuir el consumo energético, debido a los costos de carga, inicialización y mantenimiento de modelos en memoria. La evaluación de SENSE deberá considerar estos costos durante el ciclo completo de monitoreo.

1.6 Síntesis crítica y brecha de investigación

Los antecedentes revisados permiten establecer cuatro conclusiones. Primero, la integración de sensores heterogéneos y modelos de lenguaje en aplicaciones IoT ya cuenta con implementaciones experimentales [1, 6]. Segundo, la detección de ocupación mediante cámaras, variables ambientales y fusión de fuentes posee una literatura consolidada, incluso con aplicaciones en aulas [7–9]. Tercero, el muestreo adaptable, las consultas selectivas y el refinamiento de ocupación mediante modelos de razonamiento también tienen antecedentes concretos [10–12]. Cuarto, la coordinación de agentes mediante máquinas de estados y el despliegue de modelos en Edge requieren examinar por separado la lógica de ejecución y los recursos de la plataforma [2–4].

Los trabajos más cercanos obligan a acotar la comparación. Wiese et al. ya combinan percepción y muestreo ambiental adaptable en un nodo de muy bajo consumo; Farrukh y Amayri ya activan consultas adicionales según confianza; Qaisar et al. ya seleccionan casos visuales ambiguos para refinarlos con modelos generativos y, en otro estudio, comparan modelos de lenguaje con métodos clásicos para medir ocupación [10–12, 14]. En el corpus examinado no se identifica, sin embargo, una evaluación directamente comparable de una política local que parta de observaciones de radar y ambiente para decidir cuándo procesar visión y ejecutar un SLM, y que mida en la misma Raspberry Pi la calidad contextual, los costos completos y el aporte incremental del SLM frente a reglas con idéntica evidencia. Esta formulación describe la combinación y el protocolo de evaluación propuestos, no la invención individual de sus componentes.

A partir de esta observación, se plantea como brecha de investigación la necesidad de determinar si una estrategia de adquisición y procesamiento guiada por el estado contextual puede mantener una identificación adecuada de las condiciones

del entorno utilizando menos recursos que una arquitectura de ejecución continua. Asimismo, resulta necesario establecer en qué situaciones el razonamiento mediante SLM aporta beneficios frente a mecanismos deterministas que disponen de la misma información. Esta brecha se limita al conjunto de publicaciones revisadas y no constituye una afirmación de inexistencia de investigaciones relacionadas fuera de él.

Para abordar estas cuestiones, SENSE deberá diferenciar experimentalmente los efectos de la integración multimodal, la adquisición adaptativa y el razonamiento generativo. Comparar únicamente un sistema convencional con la arquitectura completa dificultaría identificar qué componente produce las diferencias observadas. Por ello, la evaluación deberá incorporar configuraciones de referencia y pruebas que permitan aislar las contribuciones de los mecanismos propuestos, considerando tanto la calidad de comprensión como el costo de ejecución.

1.7 Aporte propuesto de SENSE

SENSE propone una arquitectura multiagente multimodal adaptativa para el monitoreo inteligente de aulas y laboratorios universitarios. Su diseño se fundamenta en tres componentes relacionados: representación contextual, adquisición adaptativa de información y razonamiento mediante SLM.

La representación contextual integrará observaciones ambientales, presencia humana e información visual, diferenciando mediciones, estimaciones e información desconocida. A partir de ella, el orquestador determinará cuándo resulta necesario activar componentes adicionales de percepción o razonamiento. La estrategia considerará las necesidades de información y los recursos disponibles en una Raspberry Pi 5 de 8 GB, evitando asumir que todas las situaciones requieren el mismo nivel de procesamiento.

La arquitectura será evaluada mediante comparaciones con estrategias de procesamiento continuo y mecanismos deterministas. La calidad contextual se observará por dimensión mediante matrices de confusión, macro-F1, eventos omitidos, falsas alarmas y error de conteo cuando corresponda; el costo incluirá latencia, activaciones de componentes, CPU, memoria, potencia y energía. Asimismo, se examinará la contribución específica del SLM mediante afirmaciones no sustentadas y solicitudes innecesarias de información, además de la calidad de interpretación. Para presencia y conteo, los investigadores registrarán observaciones humanas con marcas de tiempo, independientes de las predicciones del sistema; este registro no se tratará como una medición de las magnitudes ambientales.

De esta manera, la investigación busca aportar evidencia experimental sobre el compromiso entre comprensión contextual y eficiencia de recursos, estableciendo cuándo resulta conveniente adquirir información adicional y utilizar diferentes niveles de inteligencia dentro de un dispositivo Edge IoT. Su contribución no consiste en introducir de manera aislada sensores, agentes o modelos de lenguaje, sino en evaluar su coordinación adaptativa para interpretar un entorno físico bajo restricciones computacionales reales.

CAPÍTULO II

MARCO TEÓRICO

SENSE se fundamenta en la relación entre computación consciente del contexto, fusión de información multimodal, percepción activa, arquitecturas basadas en agentes y ejecución local de modelos de lenguaje pequeños. Estos conceptos no son equivalentes ni intercambiables. Un sistema puede integrar varios sensores sin comprender una situación, emplear una máquina de estados sin representar el estado físico del entorno o ejecutar un modelo de lenguaje en el borde sin utilizar los recursos de manera eficiente. Por ello, el marco teórico delimita la función de cada concepto dentro del problema de investigación.

La exposición se organiza desde la representación del contexto hasta su costo de procesamiento. Primero se establece qué información constituye el contexto del sistema; después se examinan la fusión temporal y el tratamiento de información incompleta; finalmente, se describen la coordinación de componentes, el papel acotado del SLM local y las magnitudes necesarias para evaluar eficiencia. Las decisiones concretas de implementación, los umbrales y el protocolo experimental corresponden al marco metodológico.

2.1 Computación consciente del contexto

Dey define el contexto como la información que puede emplearse para caracterizar la situación de una entidad, donde una entidad puede ser una persona, un lugar o un objeto relevante para la interacción entre el usuario y la aplicación [15]. Esta definición desplaza la atención desde una lista fija de sensores hacia la utilidad

de la información para describir una situación. En un aula, por ejemplo, una lectura de temperatura, una detección de presencia y una estimación visual no constituyen por separado la situación del espacio; son observaciones parciales cuyo significado depende de su procedencia, momento de captura, alcance y relación con la pregunta que el sistema intenta responder.

La computación consciente del contexto utiliza esa información para adaptar el comportamiento de una aplicación [15]. Tal adaptación exige distinguir el dato observado de la interpretación construida a partir de él. Una medición ambiental, una detección de presencia y una estimación visual describen dimensiones y alcances distintos; además, toda observación queda condicionada por la ubicación del sensor, su cobertura y las condiciones de captura. Ninguna observación individual equivale al estado completo del ambiente.

En SENSE se adoptan tres niveles de estado como decisión conceptual. El *estado físico* x_t representa lo que sucede realmente en el entorno en el instante t y solo puede observarse de manera parcial. El *estado de conocimiento* C_t reúne lo que el sistema ha medido o estimado, junto con sus limitaciones. El *estado de ejecución* q_t describe la fase operativa del orquestador, por ejemplo, adquisición sensorial, inferencia visual o registro. Así, que q_t indique `visual_inference` no significa que el aula esté ocupada, y una ausencia reportada por el radar tampoco demuestra que todo el espacio físico esté vacío.

Para conservar esta separación, una observación puede representarse conceptualmente como

$$o_i = (s_i, t_i, v_i, u_i, \rho_i, \kappa_i, p_i), \tag{II.1}$$

donde s_i identifica la fuente, t_i el instante de observación, v_i el valor, u_i la unidad, ρ_i el alcance espacial o semántico, κ_i las marcas de calidad y p_i la procedencia. El

estado de conocimiento C_t se construye a partir de estas observaciones sin eliminar los valores desconocidos, antiguos o contradictorios. Esta representación es una propuesta de SENSE; la literatura sobre fusión multisensor respalda la necesidad general de considerar la imperfección y diversidad de los datos, pero no prescribe esta estructura específica [16].

2.2 Fusión de información multimodal y temporalidad

La fusión multisensor combina información procedente de distintas fuentes para construir una descripción más útil que la obtenida mediante cada fuente de forma aislada. Khaleghi et al. señalan que este proceso debe afrontar imperfección de los datos, diferencias entre tecnologías sensoriales y diversidad de las condiciones de observación [16]. La multimodalidad de SENSE surge porque las variables ambientales, la presencia por radar y la evidencia visual describen dimensiones diferentes del entorno. Estas modalidades pueden ser complementarias, cuando cada una aporta una variable distinta, o parcialmente redundantes, cuando dos fuentes ofrecen evidencia sobre un mismo aspecto contextual.

La complementariedad no elimina la necesidad de delimitar lo que cada modalidad permite inferir. El radar puede aportar evidencia de presencia dentro de una región cubierta, pero no un conteo general fiable; la visión puede estimar ocupación dentro del campo de la cámara, aunque su resultado depende de iluminación y oclusiones; y una variación ambiental no identifica por sí sola su causa. Por ello, la fusión no debe convertir observaciones limitadas en afirmaciones más amplias. Una salida contextual debe mantener la relación entre cada inferencia y las fuentes que la sustentan, además de hacer visibles los desacuerdos.

La dimensión temporal es parte de la semántica de la observación. Si el sistema interpreta conjuntamente datos obtenidos en momentos muy distintos, puede

describir como simultáneos hechos que no lo fueron. La antigüedad de una observación en el instante t puede expresarse mediante

$$\Delta t_i = t - t_i, \tag{II.2}$$

y compararse con un criterio de vigencia definido para la variable y la tarea. Este criterio no tiene por qué ser igual para temperatura, presencia y visión: su elección forma parte del diseño experimental. La sincronización, la ausencia de datos y los conflictos entre fuentes deben conservarse en C_t, en lugar de resolverse siempre mediante la lectura más reciente o una prioridad fija [16].

La fusión tampoco obliga a introducir las señales crudas en un único modelo multimodal. Puede realizarse a nivel de datos, características, representaciones o decisiones, según la información disponible y el costo aceptable. MiniCPM-V demuestra que un modelo visión–lenguaje puede integrar imágenes y texto mediante una arquitectura optimizada para dispositivos finales [13]; sin embargo, SENSE plantea como alternativa que un componente visual especializado produzca resultados estructurados y que el SLM reciba únicamente el contexto necesario. Ambas estrategias pierden y conservan información de manera diferente, por lo que su conveniencia no puede asumirse sin evaluación.

2.3 Incertidumbre y adquisición adaptativa de información

La incertidumbre contextual no se reduce a una única puntuación. Puede originarse porque un campo nunca fue observado, porque la observación perdió vigencia, porque un sensor comunicó un error, porque dos modalidades discrepan o porque el alcance de una fuente no cubre la pregunta formulada. Estas condiciones requieren tratamientos distintos: adquirir un dato faltante, renovar una lectura antigua,

diagnosticar el sensor, conservar un conflicto o declarar que la evidencia disponible no permite responder. Representar explícitamente `unknown`, `stale` y `conflicting` evita que la ausencia de evidencia se transforme en evidencia de ausencia.

Una puntuación producida por un clasificador o por un modelo generativo tampoco debe interpretarse automáticamente como probabilidad de acierto. La calibración exige que las probabilidades predichas correspondan empíricamente con la frecuencia de resultados correctos; Guo et al. muestran que redes neuronales modernas pueden presentar descalibración y estudian métodos de calibración posteriores al entrenamiento [17]. En consecuencia, SENSE puede registrar una puntuación del modelo como metadato, pero solo podrá denominarla confianza calibrada si existe un procedimiento y un conjunto de evaluación que demuestren esa propiedad.

La adquisición adaptativa parte de una necesidad de información: una diferencia explícita entre lo que se conoce y lo que se requiere para contestar una pregunta contextual. Zhang y Ji formulan la selección activa de sensores como un compromiso entre ganancia de información y costo de adquisición, señalando que evaluar todas las combinaciones sensoriales puede resultar computacionalmente intratable [18]. Inspirada en este principio, SENSE propone como formulación conceptual, no como ecuación reproducida literalmente de esa fuente, que la utilidad esperada de ejecutar una acción perceptiva a puede escribirse como

$$U(a \mid C_t) = \mathbb{E}[IG(a \mid C_t)] - \lambda\, \widehat{c}(a), \tag{II.3}$$

donde IG representa la ganancia informativa esperada, $\widehat{c}(a)$ un costo estimado y λ la importancia relativa asignada al uso de recursos. Esta ecuación organiza el razonamiento teórico, pero no implica que SENSE ya disponga de probabilidades calibradas, un estimador de costo validado o una política óptima.

La percepción activa extiende esta idea a decisiones secuenciales bajo observabilidad parcial y restricciones de recursos. Satsangi et al. estudian la selección dinámica de sensores mediante formulaciones POMDP y muestran que el crecimiento del espacio de acciones plantea un problema de escalabilidad [19]. Este antecedente justifica considerar el valor y el costo de nuevas observaciones, pero no obliga a implementar un POMDP completo. Para un prototipo trazable, una política basada en reglas sobre información faltante, antigüedad, alcance y conflicto puede constituir un punto de partida evaluable; la estimación probabilística de utilidad solo se justificaría si esa formulación sencilla resulta insuficiente.

2.4 Agentes, orquestación y máquinas de estados

Wooldridge y Jennings describen a los agentes a partir de propiedades como autonomía, reactividad, proactividad y capacidad de interacción, y distinguen entre teorías, arquitecturas y lenguajes orientados a agentes [20]. En SENSE, el término *agente* se emplea de manera operativa para designar un componente con responsabilidad delimitada, entradas y salidas explícitas y capacidad de actuar sobre el flujo del sistema. Esta definición no exige que cada agente contenga un modelo de lenguaje: la ingesta sensorial, el almacenamiento contextual, la política de adquisición y la telemetría pueden ser componentes deterministas.

Una arquitectura multiagente distribuye responsabilidades para que los errores y costos de un componente sean observables. El agente de ingesta valida y normaliza lecturas; el adaptador visual ejecuta percepción cuando la política lo solicita; el almacén contextual conserva observaciones y vigencia; el controlador selecciona la siguiente acción; y el intérprete SLM opera sobre información estructurada. Esta separación constituye una hipótesis de diseño de SENSE. Su valor deberá demostrarse mediante interfaces comprobables y ablaciones, no por el número de componentes denominados agentes.

La orquestación gobierna el orden de ejecución, las precondiciones y las transiciones entre componentes. Una máquina de estados finitos representa este control mediante un conjunto de estados operativos Q, eventos Σ y una función de transición

$$\delta : Q \times \Sigma \to Q. \tag{II.4}$$

Los formalismos de estados permiten describir sistemas reactivos y, en extensiones como los *statecharts*, incorporar jerarquía, concurrencia y comunicación [21]. En el alcance de SENSE, la FSM debe hacer explícitos pasos como espera, adquisición, inferencia, validación, registro y manejo de errores; no representa directamente si el aula está vacía, ocupada o presenta un cambio ambiental.

LEAF ofrece un antecedente contemporáneo de coordinación de expertos SLM mediante un motor de decisión basado en FSM para tareas del IIoT [3]. Su aporte muestra que es posible combinar control determinista y especialistas generativos, pero su FSM organiza la ejecución de tareas y herramientas. SENSE traslada esa distinción al monitoreo físico: el control del flujo permanece determinista y auditable, mientras que el SLM se reserva para interpretaciones que no puedan resolverse adecuadamente con reglas. De este modo, el modelo generativo no sustituye la lectura sensorial ni controla funciones críticas, y cualquier salida debe conservar la procedencia de la evidencia utilizada.

2.5 SLM local e integración de información visual

Un modelo de lenguaje pequeño se entiende aquí de manera operacional como un modelo preentrenado cuyo tamaño y forma de ejecución permiten considerar su despliegue local en el hardware objetivo. No existe un umbral universal de parámetros que garantice esa condición: la memoria disponible, la longitud del contexto, la

cuantización, el motor de inferencia y la carga concurrente influyen en la viabilidad. La literatura sobre SLM para IoT y los estudios de despliegue en dispositivos restringidos coinciden en que la selección debe realizarse conjuntamente con el hardware y la tarea [2, 5].

La cuantización reduce la precisión numérica con la que se representan los pesos y, con ello, puede disminuir el almacenamiento requerido [2, 5]. Para un modelo con N parámetros y una representación idealizada de b bits por parámetro, la memoria de los pesos puede aproximarse por

$$M_{\text{pesos}} \approx \frac{Nb}{8}. \tag{II.5}$$

La expresión no incluye caché de atención, activaciones, contexto, búferes del motor ni memoria del resto del sistema. Por tanto, que los pesos quepan en 8 GB no demuestra que el modelo pueda operar con latencia aceptable junto con sensores y visión. Los resultados de inferencia en computadoras de placa reducida sirven como referencia de factibilidad, pero no sustituyen un *benchmark* del sistema integrado [4].

La integración visual admite dos esquemas conceptuales. En el primero, un modelo visión–lenguaje procesa directamente imágenes y texto; MiniCPM-V constituye evidencia de que esta clase de modelo puede optimizarse para plataformas finales [13]. En el segundo, un modelo visual especializado produce estimaciones estructuradas, como presencia o conteo dentro de una región de interés, y el SLM interpreta esos resultados junto con las observaciones ambientales. SENSE adopta inicialmente el segundo esquema porque facilita atribuir costos y errores a cada modalidad, aunque puede perder detalles presentes en la imagen original. Esta elección es una delimitación experimental, no una superioridad establecida.

El SLM local recibe hechos estructurados y debe separar en su salida lo observado, lo inferido, lo desconocido y la información adicional solicitada. Su función

consiste en relacionar evidencias, explicar conflictos o formular recomendaciones no críticas; no debe inventar lecturas ni convertir el eCO_2, un valor equivalente calculado por el algoritmo del ENS160, en una medición directa de CO_2 [22]. El ajuste fino tampoco se adopta por defecto: la evidencia disponible muestra que aumentar parámetros entrenables o prolongar la adaptación no garantiza un mejor resultado para toda tarea [5]. Primero debe comprobarse si el modelo base satisface el esquema de salida y si aporta valor frente a reglas con la misma evidencia.

2.6 Eficiencia computacional y energética en el borde

La eficiencia de un sistema Edge no es una propiedad única, sino un conjunto de compromisos entre calidad de interpretación, latencia y uso de recursos. Los estudios de inferencia en computadoras de placa reducida permiten comparar velocidad de generación y consumo de recursos bajo configuraciones controladas, pero una carga aislada no representa la latencia de todo el sistema [4]. En SENSE, la latencia extremo a extremo incluye adquisición, colas, preprocesamiento, carga del modelo, inferencia, validación y registro. En consecuencia, los *tokens* por segundo describen solo una parte del comportamiento del SLM. Para caracterizar la distribución temporal se propone informar, al menos, mediana y p95, además de distinguir arranque en frío y régimen estable.

El uso de recursos computacionales debe registrar CPU, memoria residente y pico de RAM, además de eventos de intercambio, temperatura o reducción de frecuencia cuando se presenten. Estas magnitudes son relevantes porque la inferencia comparte la Raspberry Pi con adquisición sensorial, visión y orquestación. Los estudios sobre despliegue restringido muestran que modelo, motor y configuración producen comportamientos diferentes, de modo que el número de parámetros por sí solo no predice la ejecución del sistema [2, 4, 5].

La potencia y la energía son magnitudes relacionadas, pero distintas. La potencia instantánea $P(t)$ se expresa en vatios, mientras que la energía consumida durante el intervalo $[t_0, t_1]$ se define como

$$E = \int_{t_0}^{t_1} P(t)\, dt. \tag{II.6}$$

Si el tiempo se expresa en segundos, el resultado se obtiene en julios; si se integra potencia en vatios respecto de horas, se obtiene en Wh. El porcentaje de CPU o la duración de una tarea no permiten deducir por sí solos la energía consumida. Para SENSE se plantea medir el consumo de red por ejecuciones completas con un medidor de enchufe dotado de pantalla, situado antes de la fuente de alimentación. La energía se obtendría de la diferencia entre lecturas inicial y final de un contador Wh/kWh, siempre que el equipo incluya esa función y su resolución sea suficiente para el ensayo. Sin un registro temporal adecuado, esa medición no permite atribuir energía a eventos breves o a componentes individuales; el modelo y las especificaciones del instrumento deben verificarse antes de fijar el protocolo.

Una política adaptativa puede evitar activaciones de cámara o inferencias, pero una reducción en el número de llamadas no implica automáticamente menor energía total. La carga y descarga de modelos, su permanencia en memoria, el tiempo de espera y las transiciones entre componentes también introducen costos. Por ello, el costo de una decisión debe observarse en el ciclo completo y no únicamente durante la generación del modelo. La selección activa de sensores proporciona el fundamento para comparar valor informativo y recursos [18, 19]; el ahorro efectivo de SENSE, en cambio, constituye una hipótesis que debe medirse.

Este marco conduce a evaluar SENSE en dos ejes inseparables: calidad contextual y costo de ejecución. Una configuración será más eficiente solo si alcanza un

nivel de desempeño contextual comparable o superior con menor consumo de recursos, o si logra una mejora de comprensión cuyo costo adicional esté explícitamente caracterizado. Esta formulación evita confundir menor actividad computacional con mejor sistema y permite examinar por separado el aporte de la multimodalidad, la adquisición adaptativa y el SLM local.

CAPÍTULO III

MARCO METODOLÓGICO

La investigación propone implementar SENSE en una Raspberry Pi 5 y comparar, bajo las mismas escenas y restricciones de hardware, el aporte de tres fuentes de percepción, de una política de adquisición adaptativa y de un modelo pequeño de lenguaje (SLM) local. La metodología especifica la arquitectura que se construirá, las unidades de observación, los comparadores y las mediciones necesarias para evaluar esas decisiones. Se trata de un protocolo experimental: los resultados y los valores operativos que dependen del montaje físico aún no existen.

3.1 Diseño del estudio

El estudio será experimental y comparativo. La primera pregunta es qué información contextual añade combinar ambiente, presencia y visión frente a disponer de cada fuente por separado. La segunda es si solicitar visión solo cuando una pregunta contextual lo requiere reduce trabajo sin omitir un número inaceptable de eventos. La tercera es si, con exactamente la misma evidencia, el SLM produce interpretaciones más completas y sustentadas que reglas deterministas, y a qué costo. La respuesta ante observaciones ausentes, antiguas o contradictorias se evaluará en los tres contrastes.

Las hipótesis operativas son: H1, la combinación aumenta la cobertura de dimensiones contextuales respaldadas por observaciones frente a la mejor modalidad individual, sin perder exactitud de presencia en las regiones comparables; H2, la

política adaptativa reduce las activaciones visuales por unidad de tiempo y mantiene la tasa de eventos omitidos dentro de un margen prefijado; H3, el SLM aumenta la cobertura de respuestas sustentadas frente a reglas con idénticos datos y preguntas. Cada mejora se interpretará junto con latencia y consumo de recursos. Ninguna hipótesis presupone que SENSE supere a todos los comparadores en todas las métricas.

Se usarán tres unidades de análisis. La *ventana* servirá para clasificar presencia y evaluar la vigencia del contexto; el *evento*, para entradas, salidas, activaciones y tiempo de respuesta; y la *ejecución completa*, para memoria, carga computacional y energía de red. Las ventanas de una misma sesión son observaciones correlacionadas y no se contarán como réplicas independientes. La duración de ventana, la tolerancia de emparejamiento temporal y las repeticiones se fijarán en un piloto independiente de la evaluación final.

3.2 Arquitectura de SENSE

La arquitectura tendrá tres agentes de percepción con responsabilidades acotadas y un orquestador en Rust. El *agente de ambiente* leerá SHT40 y ENS160, validará unidades y marcas de tiempo, y emitirá temperatura, humedad y los indicadores estimados del ENS160. El *agente de presencia* leerá el HLK-LD2410C y emitirá presencia o movimiento dentro de la cobertura comprobada del radar. El *agente de visión* capturará una imagen con la IMX219 solo cuando reciba una solicitud y aplicará un detector local de personas para estimar el conteo visible en la región definida. Estos agentes se distinguen por fuente, interfaz de salida y política de activación; no se supone que razonen de forma autónoma ni que cada uno requiera un modelo de lenguaje.

Tabla 3.1: Contrato mínimo de los agentes de percepción propuestos.

Agente	Entrada y activación	Salida con procedencia	Límite
Ambiente	SHT40 y ENS160; lectura periódica	Temperatura, humedad, TVOC y eCO_2 estimado; tiempo y validez	No infiere ocupación
Presencia	Radar; lectura periódica o evento disponible	Presencia o movimiento dentro de cobertura; tiempo y calidad	No cuenta personas
Visión	IMX219 y detector; solicitud del orquestador	Personas visibles estimadas; región, tiempo y calidad	No identifica individuos

El orquestador integrará las observaciones en el contexto vigente, evaluará qué dato falta para la pregunta actual y decidirá si solicita visión o interpretación. Un componente SLM local recibirá exclusivamente observaciones estructuradas y podrá producir una explicación o respuesta validada por esquema; no leerá imágenes crudas ni controlará directamente los sensores. Un registro de telemetría guardará observaciones, solicitudes, transiciones y tiempos. La figura 3.1 queda reservada para representar esas interfaces, la activación condicional de visión y la separación entre la referencia humana y las salidas del sistema.

Diagrama pendiente: tres agentes de percepción, orquestador Rust, contexto, SLM y telemetría.

Figura 3.1: Arquitectura funcional propuesta de SENSE. Esquema pendiente de elaboración.

Una observación contendrá fuente, identificador, tiempo, valor, unidad, región de validez y banderas de calidad. El contexto conservará por separado presencia en la cobertura radar, conteo visible, variables ambientales, antigüedad, conflictos y necesidades de información. Admitirá valores `unknown`, `stale` y `conflicting`; por ejemplo, una persona fuera del radar no implica que el aula esté vacía. La acción siguiente del orquestador será una decisión registrada, no una propiedad del aula.

Esta distinción entre situación física, conocimiento disponible y estado de ejecución evita mezclar información de alcance o tiempo distinto [15, 16].

3.3 Máquina de estados y política del orquestador

La máquina de estados finitos modelará el *ciclo de ejecución* del orquestador, no clases físicas mutuamente excluyentes del aula. Su estado inicial será `WAIT`; al llegar un intervalo de lectura o un evento pasará a `ACQUIRE`, donde reunirá observaciones disponibles sin suponer que todos los sensores responden. En `ASSESS` actualizará el contexto y evaluará vigencia, conflicto, necesidad de conteo y presupuesto de ejecución. Cuando la cámara pueda responder una necesidad concreta, solicitará `VISION` y volverá a `ASSESS` con la nueva estimación. Solo si la pregunta requiere interpretación contextual pasará a `INTERPRET`; finalmente registrará la salida en `REPORT` y regresará a `WAIT`. Un sensor que no responda se marcará como fuente ausente y permitirá continuar con la evidencia disponible. Si vence el plazo global o falla un componente indispensable para la salida requerida, se pasará a `DEGRADED`, desde donde se publicará una salida parcial o una abstención con causa explícita.

Las guardas serán reglas deterministas y trazables en el primer prototipo. Una señal positiva del radar no bastará por sí sola para activar cámara: si la pregunta exige solo presencia en su cobertura, la observación radar puede ser suficiente; si exige número de personas, se pedirá visión cuando su región pueda aportar esa información. Las llamadas a visión y SLM tendrán límites de frecuencia y tiempo; las solicitudes, motivos y fallos se registrarán para evaluar si una activación era necesaria. La figura 3.2 deberá representar las rutas ordinaria, condicional y degradada, así como el retorno desde visión a la evaluación del contexto.

TABLA 3.2: Transiciones principales de la máquina de estados del orquestador.

Origen	Guarda o evento	Acción y destino
`WAIT`	Temporizador o evento de sensor	Solicitar lecturas; `ACQUIRE`
`ACQUIRE`	Lecturas recibidas o plazo vencido	Marcar fuentes disponibles; `ASSESS`
`ASSESS`	Falta conteo, dato visual vencido o conflicto resoluble; cámara disponible	Solicitar captura; `VISION`
`VISION`	Estimación o fallo de visión	Actualizar contexto o marcar fallo; `ASSESS`
`ASSESS`	Interpretación requerida con evidencia suficiente	Enviar contexto estructurado; `INTERPRET`
`ASSESS`	Pregunta resuelta por reglas o evidencia insuficiente	Emitir respuesta o abstención; `REPORT`
`INTERPRET`	Respuesta validada	Registrar salida; `REPORT`
Cualquier estado activo	Plazo global vencido o componente indispensable fallido	Conservar evidencia válida; `DEGRADED` y luego `REPORT`
`REPORT`	Registro completado	Esperar siguiente evento; `WAIT`

Diagrama pendiente: estados, guardas y transiciones del orquestador.

FIGURA 3.2: Máquina de estados de ejecución propuesta para el orquestador. Esquema pendiente de elaboración.

3.4 Montaje y preparación del piloto

La plataforma prevista es una Raspberry Pi 5 de 8 GB con SHT40, ENS160, HLK-LD2410C y cámara IMX219. El ENS160 entrega indicadores, incluido eCO_2 estimado, y no una concentración de CO_2 medida directamente [22]. El radar informa presencia en una cobertura dependiente del montaje; no cuenta personas ni certifica ausencia en todo el espacio. Antes de medir, se comprobarán controladores, conectividad, tiempo de lectura y estabilidad de los cuatro dispositivos en la Pi.

En un aula y un laboratorio se delimitarán físicamente la región visible de la

cámara, la cobertura comprobada del radar, su intersección y las zonas ciegas. Se registrarán posición, orientación, iluminación y obstáculos. La figura 3.3 se completará con planos de ambos espacios una vez medidas las regiones; no se dibujarán alcances nominales como si fueran cobertura observada.

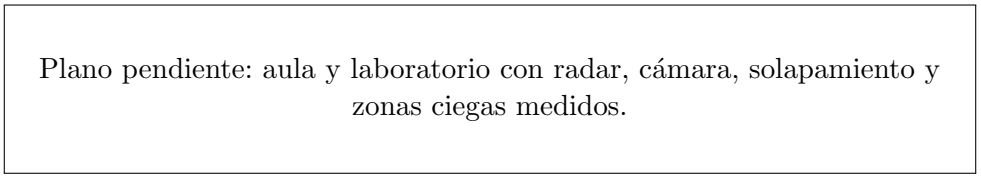


FIGURA 3.3: Regiones de observación del montaje experimental. Plano pendiente del piloto.

El piloto seleccionará un detector de personas y un SLM capaces de ejecutarse localmente con los demás componentes residentes. Se documentarán versiones, pesos, cuantización, motor, resolución de entrada, latencia y memoria; el umbral visual, la plantilla de instrucción y los parámetros de generación se fijarán antes de la prueba final. También se fijarán ventana temporal, tiempos de espera, umbrales de vigencia y límite de activaciones. Los datos del piloto no se reutilizarán como resultados finales. Si el conteo o el SLM no son factibles en la Pi bajo la carga conjunta, se acotará esa comparación y se informará el motivo.

3.5 Escenarios, referencia humana y comparadores

La evaluación combinará episodios preparados y sesiones con variación normal de luz, presencia y ambiente. Se incluirán región vacía, ingreso, salida, cambio de conteo, permanencia casi inmóvil y persona visible fuera de la cobertura radar cuando la geometría lo permita. Se ensayarán además pérdida temporal de cámara o sensor, dato vencido y discrepancia entre radar y visión. No se pretende controlar todas las combinaciones posibles: se registrarán las condiciones no controladas y los escenarios efectivamente observados. El ejemplo temporal de la figura 3.4 indicará

las acciones humanas, observaciones y decisiones que deben anotarse, sin imponer duraciones o respuestas ficticias.

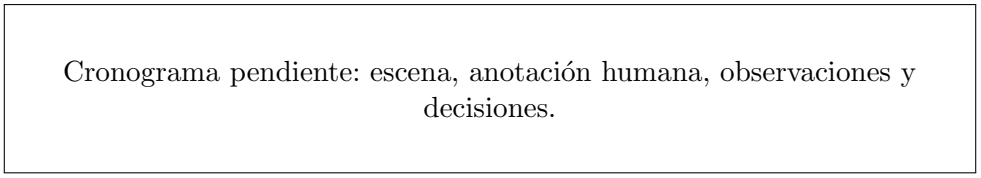


FIGURA 3.4: Cronología de un escenario con cambio de presencia y evidencia incompleta. Esquema ilustrativo pendiente.

Los investigadores anotarán presencia, conteo visible, entradas y salidas dentro de las regiones definidas, con tiempos sincronizados y sin consultar predicciones de SENSE. En un subconjunto, dos observadores anotarán por separado y se reportarán discrepancias y su resolución. La etiqueta será «no evaluable» si una oclusión impide comprobar el conteo; no se sustituirá por cero. Las intervenciones de fallo se verificarán con el registro de adquisición. La referencia humana cubre personas y eventos preparados, pero no constituye una medida patrón de temperatura, humedad, TVOC ni eCO_2; por tanto, esos indicadores se analizarán por disponibilidad, vigencia y cambios registrados, sin calificar su exactitud física ni afirmar causas o peligrosidad.

Se compararán cuatro configuraciones con el mismo hardware, detector visual, regiones, telemetría y ciclo de ejecución del orquestador; cambiarán las guardas de adquisición y el intérprete indicados. A solicitará visión periódicamente; B usará un disparo simple por evento o umbral; C empleará el contexto para decidir de forma adaptativa y responderá con reglas; D conservará la política de C y añadirá la interpretación del SLM cuando sea requerida. En A, B y C se usarán reglas diseñadas para responder a las mismas preguntas. La tabla 3.3 resume qué contraste sustenta cada pregunta.

La ablación de modalidades reproducirá una misma secuencia con fuentes ocultadas a cada variante. Esa operación mide el aporte informativo y no el ahorro

Tabla 3.3: Comparaciones previstas y factor que se modifica.

Contraste	Factor comparado	Resultado principal
Modalidades sobre una misma secuencia	Ambiente, radar, visión y combinaciones	Preguntas respondidas con respaldo por dimensión
A, B y C	Política de adquisición, manteniendo detector	Activaciones visuales y eventos omitidos
C frente a D	Reglas frente a SLM con idéntica evidencia	Calidad de respuesta y costo adicional
Fallos en cada configuración	Fuente ausente, vencida o contradictoria	Abstención apropiada y degradación

eléctrico de apagar físicamente un sensor. La cobertura contará preguntas predefinidas respondidas con evidencia válida; la exactitud de presencia y conteo se calculará solo donde exista anotación humana independiente. A frente a D será una comparación del sistema completo: como cambian política e intérprete, no se atribuirá toda diferencia al SLM. Para aislar el aporte interpretativo, reglas y SLM resolverán además el mismo conjunto de preguntas con snapshots idénticos, independientemente de qué política los invoque durante la ejecución en vivo. Una variante de SLM periódico se añadirá únicamente si el piloto demuestra que es viable y necesaria para evaluar el costo de seleccionar sus llamadas.

3.6 Procedimiento y métricas

Se usarán dos vías complementarias, representadas en la figura 3.5. La primera reproducirá secuencias anotadas para comparar políticas y modalidades sobre las mismas entradas; el registro deberá contener las capturas que cualquiera de las variantes pueda solicitar. La segunda ejecutará las configuraciones físicamente en la Pi para medir latencia extremo a extremo, carga, memoria y, si el instrumento lo permite, energía. El orden de configuraciones se aleatorizará o contrabalanceará entre sesiones. Se distinguirán arranque en frío y operación estable, y se registrarán fallos,

swap y limitación térmica. La reproducción no se presentará como una medición del consumo eléctrico de capturas reales.

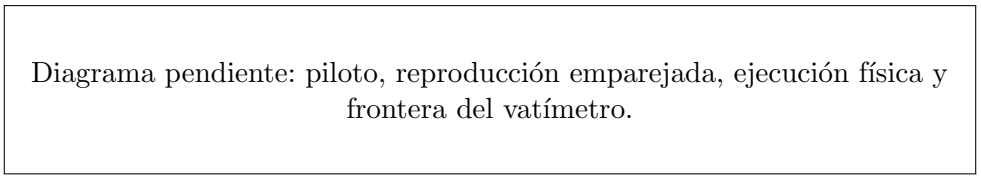


FIGURA 3.5: Protocolo de evaluación y frontera de medición eléctrica. Esquema pendiente de elaboración.

Para presencia en la región anotada se informarán matriz de confusión, precisión, exhaustividad y F1, junto con prevalencia y proporción de abstenciones. El conteo visual se evaluará mediante error absoluto medio solo en ventanas con referencia visible. Para eventos se registrarán omisiones, falsas alarmas por hora y latencia desde el evento anotado hasta la salida. La tasa de omisión será

$$R_{\text{om}} = \frac{N_{\text{omitidos}}}{N_{\text{referencia}}}. \tag{III.1}$$

donde N_{omitidos} es el número de eventos sin detección dentro de la tolerancia fijada y $N_{\text{referencia}}$ el total de eventos evaluables. Las activaciones de cámara y SLM se informarán por hora y por evento evaluable. La reducción relativa de activaciones visuales respecto de A será

$$R_{\text{vis}} = 1 - \frac{N_{\text{vis},X}}{N_{\text{vis},A}}, \tag{III.2}$$

donde X es la configuración comparada y ambos conteos corresponden a exposiciones temporales equivalentes. Esta reducción se interpretará junto con omisiones y latencia, sin equipararla automáticamente a ahorro energético.

Una rúbrica previa a la prueba calificará si cada respuesta a una pregunta contextual es correcta, completa y sustentada por observaciones identificables, o si contiene afirmaciones no sustentadas. Las abstenciones justificadas se informarán

por separado. Reglas y SLM recibirán los mismos campos y tiempos; evaluadores independientes calificarán un subconjunto sin conocer la configuración. Se informarán también CPU, memoria residente y pico, tiempos de carga de modelos y latencia de respuesta.

La medición eléctrica utilizará el vatímetro de enchufe PMB05 adquirido para el estudio, situado entre la toma y la fuente de alimentación de la Pi, manteniendo fuente y periféricos constantes. Según la comprobación comunicada por el estudiante, la unidad admite 220 V y 60 Hz y el contador acumulado avanza en pasos de 0,01 kWh, equivalentes a 10 Wh. El piloto comprobará el comportamiento del contador con la carga del montaje y la repetibilidad de las lecturas; se documentará la exactitud declarada si el manual la especifica. La duración de las ejecuciones se fijará de modo que las diferencias de interés puedan distinguirse frente al paso visible del contador. Si este permite distinguir la energía de ejecuciones completas, esta se calculará como

$$E_{\text{run}} = E_{\text{final}} - E_{\text{inicial}}, \tag{III.3}$$

donde ambas lecturas manuales corresponden a una ejecución completa de duración documentada. Se registrarán el valor y la hora de cada lectura y el procedimiento utilizado. La magnitud incluye la fuente de alimentación y todos los equipos conectados al medidor. El paso de 10 Wh no establece la exactitud del instrumento: si el contador no permite distinguir los ensayos, la hipótesis energética no se dará por verificada; el porcentaje de CPU o una lectura aislada de potencia no sustituirán Wh. Sin registro temporal de potencia tampoco se asignará energía a eventos breves o componentes individuales.

3.7 Análisis y reproducibilidad

Las métricas primarias serán: para H1, proporción de preguntas predefinidas respondidas con evidencia válida y F1 de presencia donde exista referencia humana comparable; para H2, activaciones visuales por hora y tasa de omisión; y para H3, proporción de respuestas completas y sustentadas y proporción de afirmaciones sin respaldo en las mismas preguntas emparejadas. La cobertura ambiental indica disponibilidad de lecturas, no exactitud frente a un patrón independiente. Error de conteo, latencia, memoria y energía complementarán la interpretación. El conjunto de preguntas, denominadores, margen aceptable de omisiones, número de sesiones y criterios de exclusión se fijarán tras el piloto y antes de analizar la evaluación final.

Se presentarán resultados por espacio y escenario. Las diferencias emparejadas y sus intervalos de confianza se calcularán por sesión, sin tratar ventanas correlacionadas como réplicas. Si las sesiones son suficientes, el remuestreo se hará por sesión. Una diferencia no significativa no se interpretará como equivalencia. Cada ejecución conservará identificador, versión de código y modelos, configuración, anotaciones, observaciones, transiciones de la máquina de estados, acciones, errores y tiempos; así será posible reconstruir qué evidencia produjo cada salida.

Las limitaciones principales serán cobertura de radar y cámara, oclusión, variación ambiental y humana, un único modelo de Pi y posible efecto de temperatura o carga de modelos. La autorización declarada para las pruebas se documentará junto con el consentimiento aplicable y la política efectiva de almacenamiento, acceso y eliminación de imágenes. El protocolo no incluye reconocimiento de individuos ni detección certificada de situaciones peligrosas. Ninguna conclusión sobre superioridad o ahorro se formulará antes de medir.

REFERENCIAS BIBLIOGRÁFICAS

[1] T. Domínguez-Bolaño, V. Barral, C. J. Escudero, and J. A. García-Naya, "An IoT system for a smart campus: Challenges and solutions illustrated over several real-world use cases," *Internet of Things*, vol. 25, p. 101099, 2024. [Online]. Available: https://doi.org/10.1016/j.iot.2024.101099

[2] M. Driss, S. Ben Atitallah, B. Benjdira, S. AlHalawani, A. M. Ali, and W. Boulila, "Small language models for on-device IoT intelligence: A survey on architectures, optimization, and deployment," *Internet of Things*, vol. 39, p. 102020, 2026. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S2542660526001502

[3] Q. Yang, Z. Li, J. Tang, Y. Liu, T. Guo, and Y. Wen, "LEAF: A lightweight edge agent framework with expert SLMs for the industrial internet of things," *Computers, Materials & Continua*, vol. 87, no. 2, p. 30, 2026, article number 30. [Online]. Available: https://www.techscience.com/cmc/v87n2/66586

[4] T. Nguyen and T. Nguyen, "An evaluation of LLMs inference on popular single-board computers," arXiv preprint arXiv:2511.07425, 2025. [Online]. Available: https://arxiv.org/abs/2511.07425

[5] R. Qin, D. Liu, C. Xu, Z. Yan, Z. Tan, Z. Jia, A. Nassereldine, J. Li, M. Jiang, A. Abbasi, J. Xiong, and Y. Shi, "Empirical guidelines for deploying LLMs onto resource-constrained edge devices," *ACM Transactions on Design*

Automation of Electronic Systems, vol. 30, no. 5, 2025, article 70; 58 pages. [Online]. Available: https://doi.org/10.1145/3736721

[6] J. M. Núñez V., D. M. Giraldo, S. Gómez Segura, J. M. Corchado, and F. De la Prieta, "Bioinspired small language models in edge systems for bee colony monitoring and control," *Internet of Things*, vol. 32, p. 101633, 2025. [Online]. Available: https://doi.org/10.1016/j.iot.2025.101633

[7] Z. Chen, C. Jiang, and L. Xie, "Building occupancy estimation and detection: A review," *Energy and Buildings*, vol. 169, pp. 260–270, 2018. [Online]. Available: https://doi.org/10.1016/j.enbuild.2018.03.084

[8] K. Sun, Q. Zhao, and J. Zou, "A review of building occupancy measurement systems," *Energy and Buildings*, vol. 216, p. 109965, 2020. [Online]. Available: https://doi.org/10.1016/j.enbuild.2020.109965

[9] K. Challa, I. W. AlHmoud, C. Jaiswal, B. Gokaraju, and R. Tesireo, "Gas sensors and real-time video for accurate classroom occupancy detection," *MethodsX*, vol. 14, p. 103386, 2025. [Online]. Available: https://doi.org/10.1016/j.mex.2025.103386

[10] P. Wiese, V. Kartsch, M. Guermandi, and L. Benini, "A multi-modal IoT node for energy-efficient environmental monitoring with edge AI processing," in *2025 IEEE International Conference on Omni-layer Intelligent Systems (COINS)*, 2025. [Online]. Available: https://doi.org/10.1109/COINS65080.2025.11125738

[11] F. F. Farrukh and M. Amayri, "Query-Distill: Cloud–fog collaboration with knowledge distillation and confidence-based querying for smart buildings," *Building and Environment*, vol. 287, p. 113836, 2026. [Online]. Available: https://doi.org/10.1016/j.buildenv.2025.113836

[12] I. Qaisar, K. Sun, Q. Jia, and Q. Zhao, "Experimental study on surveillance video-based indoor occupancy measurement for occupant-centric

control," *Building and Environment*, p. 115200, 2026. [Online]. Available: https://doi.org/10.1016/j.buildenv.2026.115200

[13] Y. Yao, T. Yu, A. Zhang, C. Wang, J. Cui, H. Zhu, T. Cai, C. Chen, H. Li, W. Zhao, Z. He, Q. Chen, R. Zhou, Z. Zou, H. Zhang, S. Hu, Z. Zheng, J. Zhou, J. Cai, X. Han, G. Zeng, D. Li, Z. Liu, and M. Sun, "Efficient GPT-4V level multimodal large language model for deployment on edge devices," *Nature Communications*, vol. 16, no. 1, p. 5509, 2025. [Online]. Available: https://www.nature.com/articles/s41467-025-61040-5

[14] I. Qaisar, K. Sun, and Q. Zhao, "Exploring large language models for indoor occupancy measurement in smart office buildings," *Building and Environment*, vol. 287, p. 113860, 2026. [Online]. Available: https://doi.org/10.1016/j.buildenv.2025.113860

[15] A. K. Dey, "Understanding and using context," *Personal and Ubiquitous Computing*, vol. 5, no. 1, pp. 4–7, 2001. [Online]. Available: https://doi.org/10.1007/s007790170019

[16] B. Khaleghi, A. Khamis, F. O. Karray, and S. N. Razavi, "Multisensor data fusion: A review of the state-of-the-art," *Information Fusion*, vol. 14, no. 1, pp. 28–44, 2013. [Online]. Available: https://doi.org/10.1016/j.inffus.2011.08.001

[17] C. Guo, G. Pleiss, Y. Sun, and K. Q. Weinberger, "On calibration of modern neural networks," in *Proceedings of the 34th International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, vol. 70. PMLR, 2017, pp. 1321–1330. [Online]. Available: https://proceedings.mlr.press/v70/guo17a.html

[18] Y. Zhang and Q. Ji, "Sensor selection for active information fusion," in *Proceedings of the Twentieth National Conference on Artificial Intelligence*

(AAAI-05), vol. 3. AAAI Press, 2005, pp. 1229–1234. [Online]. Available: https://auld.aaai.org/Library/AAAI/2005/aaai05-195.php

[19] Y. Satsangi, S. Whiteson, F. A. Oliehoek, and M. T. J. Spaan, "Exploiting submodular value functions for scaling up active perception," *Autonomous Robots*, vol. 42, pp. 209–233, 2018. [Online]. Available: https://doi.org/10.1007/s10514-017-9666-5

[20] M. J. Wooldridge and N. R. Jennings, "Intelligent agents: Theory and practice," *The Knowledge Engineering Review*, vol. 10, no. 2, pp. 115–152, 1995. [Online]. Available: https://doi.org/10.1017/S0269888900008122

[21] D. Harel, "Statecharts: A visual formalism for complex systems," *Science of Computer Programming*, vol. 8, no. 3, pp. 231–274, 1987. [Online]. Available: https://doi.org/10.1016/0167-6423(87)90035-9

[22] ScioSense, *ENS160 Digital Metal-Oxide Multi-Gas Sensor Datasheet*, 1st ed., ScioSense B.V., 2023. [Online]. Available: https://www.sciosense.com/wp-content/uploads/2023/12/ENS160-Datasheet.pdf